

Large language models (LLMs) with RAG technique

Punnathorn Mingkwan and Tanasai Sucontphunt

Graduated School of Applied Statistics

National Institute of Development Administration, Bangkok, Thailand

E-mail : 6510412003@stu.nida.ac.th and E-mail : tanasai.suc@nida.ac.th

ABSTRACT

(English)

The use of artificial intelligence (AI) across various industries has surged rapidly over the past decade. Technologies such as machine learning algorithms, natural language processing (NLP), and computer vision have been integrated into diverse sectors. One particularly challenging and promising area for industry advancement is the deployment of AI chatbots, or Large Language Models (LLMs), to handle specific inquiries—unique pieces of information that traditionally require human intervention. However, open-source LLMs often fall short when responding to specialized queries, such as those related to a company's product details or employee rights within an organization. Training a new model to handle these types of questions invariably demands substantial resources.

To enhance AI's ability to answer specific inquiries, the integration of Large Language Models (LLMs) with a technique known as Retrieval Augmented Generation (RAG) is being explored. RAG works by retrieving relevant information from documents to answer user queries. This approach addresses several limitations inherent in current LLMs, such as hallucination—where the model generates plausible but incorrect responses—the outdated nature of the data they contain, and the challenge of auditing the model's internal processes. By leveraging RAG, AI can provide more accurate, up-to-date, and context-specific answers, significantly reducing hallucinations and improving traceability, especially when dealing with highly specialized queries or languages with limited training data, such as Thai in private documents.

Keywords : Large Language Models (LLMs), RAG, Embeddings, Tokenization, Thai language, Natural Language Processing (NLP)

ABSTRACT

(Thai)

การใช้ปัญญาประดิษฐ์ (AI) ในอุตสาหกรรมต่างๆได้เพิ่มขึ้นอย่างรวดเร็วในช่วงทศวรรษที่ผ่านมา เทคโนโลยี AI เช่น machine learning algorithms, natural language processing (NLP), และ computer vision ได้ถูกนำไปใช้งานในอุตสาหกรรมในหลากหลายส่วน งานส่วนหนึ่งที่มีความท้าทายและมีโอกาสช่วยให้ภาคอุตสาหกรรมต่างๆพัฒนาไปในทิศทางที่ดีขึ้นก็คือ การใช้ Chatbot (AI) หรือในอีกชื่อหนึ่งคือ Large Language Models (LLMs) ในการช่วยตอบคำถามที่เฉพาะเจาะจง (Unique informations) ซึ่งโดยปกติจะต้องใช้คนในการตอบคำถามเหล่านี้ และ LLMs ที่มีลักษณะเป็น Open source ไม่สามารถตอบแทนได้ เช่น ข้อมูลเกี่ยวกับสินค้าของบริษัท ข้อมูลเกี่ยวกับสิทธิ์ของพนักงานภายในบริษัท เป็นต้น ซึ่งการ Train model ขึ้นมาใหม่สำหรับการตอบคำถามประเภทนี้ ก็หลีกเลี่ยงไม่ได้ที่จะต้องใช้ทรัพยากรจำนวนมากในการทำ

สำหรับการนำเทคโนโลยี AI เข้าไปปรับใช้กับการช่วยตอบคำถามที่เฉพาะเจาะจง จะมีการนำ Large Language Models (LLMs) มาพัฒนาความสามารถด้วยเทคนิคซึ่งเรียกว่า Retrieval Augmented Generation (RAG) โดยเทคนิคดังกล่าวจะมีการทำงานโดยใช้วิธีค้นหาข้อมูลภายในเอกสารและนำเอกสารไปตอบคำถามตามที่ผู้ใช้งานได้ถามคำถามลงไป สาเหตุที่ต้องใช้ RAG สืบเนื่องมาจากความสามารถของ LLMs ในปัจจุบัน แม้ว่าจะสามารถถาม-ตอบได้อย่างแม่นยำและตรงใจผู้ใช้งานทั่วไป ขณะเดียวกันก็ยังพบปัญหาที่เรียกว่า hallucination หรืออาการประสาทหลอน, ปัญหาข้อมูลภายใน LLMs ที่ไม่ทันสมัยตามช่วงเวลา, ปัญหาของ LLMs ที่ไม่สามารถตรวจสอบกระบวนการทำงานภายใน model ได้ และปัญหาอื่นๆอีกมากมาย ด้วยเหตุผลดังกล่าว จึงทำให้ RAG เป็นเทคนิคที่จะช่วยให้ AI มีข้อมูลที่ทันสมัยและเจาะจงมากขึ้น ตอบคำถามได้ดีขึ้น มีอาการ hallucination ลดลง และสามารถตรวจสอบกระบวนการทำงานภายในได้ โดยเฉพาะการตอบคำถามที่มีความเฉพาะเจาะจงเป็นพิเศษและใช้ภาษาที่มักจะมีการ train ภายใน LLMs ซึ่งมีสัดส่วนปริมาณน้อย เช่น การถามข้อมูลที่อยู่ในเอกสารส่วนตัวเป็นภาษาไทย เป็นต้น

Keywords : Large Language Models (LLMs), RAG, Embeddings, Tokenization, Thai language, Natural Language Processing (NLP)

1. Overall

คือการพยายามใช้ LLM ในการสื่อสารภายในองค์กร หรือ สื่อสารในเรื่องที่เฉพาะเจาะจง ซึ่ง LLM อาจไม่ได้ ถูก Train มาก่อน

เช่น นาย A ทำธุรกิจเกี่ยวกับการขายสินค้าออนไลน์ และมี ลูกค้าแชทเข้ามาถามข้อมูลทุกวัน และถามคำถามซ้ำๆ พอคิดว่าจะเอา ChatGPT หรือ Ai มาช่วยในการตอบลูกค้า ก็พบว่า ChatGPT อาจจะไม่สามารถตอบคำถามเกี่ยวกับ สินค้าของนาย A ได้

จึงต้องมีการปรับ ให้ LLM สามารถ ตอบคำถามลูกค้าแทน นาย A ได้ ซึ่งวิธีการนั้นถูกเรียกว่า RAG Technique

Concept ของ RAG (Figure 1.1)

ก็คือ จะมีการใช้ Algorithm 2 ตัว

ตัวแรกคือ LLMs ซึ่งใช้ในการตอบคำถามทั่วไป

ตัวที่ 2 คือ Embedding model ซึ่งใช้ในการตอบข้อมูลที่ เป็น Specific หรือข้อมูลที่ไม่ได้ถูก Train กับ LLMs มาก่อน




Figure 1.1 RAG Concept

2.Method

การทำงานร่วมกันของ ทั้ง 2 Algorithm จะมีวิธีการดังนี้



Figure 1.2 RAG Details

2.1) เริ่มต้นด้วย user ถามคำถามเข้ามา

จากนั้นจะมีการเอาคำถามของ user ไปแปลงเป็น vectors แล้วนำ vectors นี้ไป match กับ vectors ของเอกสาร (ซึ่งแน่นอนว่าเอกสารได้ถูกแปลงเป็น vectors อยู่ก่อนแล้ว และเก็บไว้ใน Vector database)

2.2) เมื่อได้ vector ของเอกสารที่ match กับคำถามมากที่สุดออกมา ก็จะมีการนำเอาเนื้อหาของเอกสารนั้น ส่งไปให้กับ LLMs เพื่อให้ LLMs ใช้อ้างอิงในการตอบ (Figure 1.2)

2.3) สำหรับในส่วนของ วิธีการหาเอกสารที่ใช้ที่สุดเพื่อส่งให้กับ LLMs หรือ วิธีการ match vector ของคำถามกับคำตอบ ก็มีได้หลากหลายวิธี

2.3.1) วิธีแรก คือวิธีการ match vector ด้วยสมการคล้ายๆ การทำ cosine similarity แต่อาจจะซับซ้อนกว่า ซึ่งอธิบายง่ายๆก็คือการ search เอกสารด้วย keyword นั้นเอง เช่น ค้นหาว่า แมว ก็จะได้เอกสารที่มี keyword แมว เยอะที่สุดออกมา

วิธีนี้เรียกว่า keyword search

2.3.2) ถัดมาคือ semantic search วิธีนี้คือการค้นหาคำที่อาจจะเกี่ยวข้องกับคำค้นหา เช่น ค้นหาว่าแมว เอกสารที่ได้อาจจะไม่ใช่เอกสารที่มี keyword แมว เยอะที่สุด แต่เป็นเอกสารที่มี keyword อื่นๆที่อาจจะเกี่ยวข้องกับ แมว เช่น keyword สุนัข หรือคำว่า จีบหนู เป็นต้น

2.3.3) วิธีที่ 3 คือ Hybrid search

คือเอาทั้ง keyword search & semantic search มารวมกัน โดยวิธีที่ถูกนำมาประยุกต์ใช้ใน Project นี้คือ Search หา top n ด้วยวิธีการ semantic search ก่อน จากนั้นก็เอา top n นั้นมา re rank ด้วยการทำ keyword search เพื่อเอาเอกสารที่เป็น top rank ส่งไปให้กับ LLMs

2.4) Details

BM25: an intuitive view




Figure 1.3 BM25Okapi

ส่วนนี้คือรายละเอียดของ keyword search (Figure 1.3) คือจะมีสมการเบื้องหลังในการ match vector ของคำถาม และคำตอบ สมการนี้มีชื่อว่า BM25 Okapi โดยตัวสมการ จะทำการหา keyword ที่เกิดซ้ำมากที่สุด ในเอกสาร และมีการให้ weight เพื่อลดโอกาสที่จะได้เอกสารที่มี keyword เกิดขึ้นซ้ำๆ ในเอกสาร แต่ไม่ใช่เอกสารที่เป็นคำตอบ




Figure 1.4 Embedding model

ส่วนนี้คือรายละเอียดของ semantic search คือจะมีการใช้ Embedding model ในการแปลง text ให้เป็น vector (Figure 1.4) ซึ่ง model ประเภทนี้จะถูก Train ด้วยการเอา text มาคำนวณหาโอกาสที่จะเกิดคำต่อไป ด้วยวิธีการที่เรียกว่า skip n-gram

Source Text	Training Samples generated from source text
I will have orange juice and eggs for breakfast	(will, I) (will, have) (will, orange)
I will have orange juice and eggs for breakfast	(have, I) (have, will) (have, orange) (have, juice)
I will have orange juice and eggs for breakfast	(orange, will) (orange, have) (orange, juice) (orange, and)
I will have orange juice and eggs for breakfast	(juice, have) (juice, orange) (juice, and) (juice, eggs)
I will have orange juice and eggs for breakfast	(and, orange) (and, juice) (and, eggs) (and, for)
I will have orange juice and eggs for breakfast	(eggs, juice) (eggs, and) (eggs, for) (eggs, breakfast)
I will have orange juice and eggs for breakfast	(for, and) (for, eggs) (for, breakfast)

Figure 1.5 N-gram method

ในรูปตัวอย่างนี้ (Figure 1.5) คือ n-gram = 2 คือ model จะจำคำที่จะเกิดถัดไปจากคำปัจจุบัน จำนวน 2 คำ และคำก่อนหน้า 2 คำ

จากนั้นจะมีการเอาคำปัจจุบัน ไปคำนวณหา probability ว่าคำไหนมักจะเกิดถัดไปจากคำปัจจุบันมากที่สุด




Figure 1.6 Skip-gram model

รูปนี้ (Figure 1.6) คือตัวอย่างวิธีการหาคำที่เกี่ยวข้องกับคำค้นหาของ Embedding model

คือในแต่ละคำ จะมี vector ของตัวเอง ซึ่งได้มาจากการ train skip n-gram

จากนั้นจะมีการเอา vector ของคำ 2 คำที่มีทิศทางและขนาดใกล้เคียงกันมา บวก ลบ กัน

ก็จะได้เป็นค่าใกล้เคียงออกมา

เช่นในตัวอย่างมีการหา vector ของ 2 คำ ที่มีขนาดและทิศทางใกล้เคียงกับคำว่า man กับ woman

ก็ปรากฏว่าเป็นคำว่า king กับ queen

ซึ่งหมายความว่า ถ้าเราค้นหาคำว่า man แทนที่จะได้เอกสารที่มี keyword ว่า man เยอะๆ ก็จะได้คำอื่นมาด้วย เช่นคำว่า king เป็นต้น

หลังจากที่อธิบายวิธีการทำงานในการ match vector ของคำถามกับคำตอบ ซึ่งได้ถูกนำมาใช้ใน project

นี้ หลังจากนี้คือเมื่อ embedding model ได้เอกสารที่เหมาะสมออกมาแล้ว ในรูปแบบ text

ก็จะมีการส่งให้ LLMs เอาไปใช้ในการอ้างอิงสำหรับการตอบคำถาม user

วิธีการที่ส่งเอกสารให้ LLMs คือนำ text จาก Embedding model มาเขียนเป็น prompt

ก็จะมีปุ่มสำหรับ upload เอกสารได้ มี status ของตัว chatbot Show อยู่ด้านบนว่าพร้อมตอบหรือยัง

3. Models

3.1) Embedding model

สำหรับใน Project นี้จะใช้ model ทั้งหมด 3 ตัว ที่ถูก Train แบบ multilingual บ้าง Train เฉพาะภาษาไทยบ้าง โดยหลักๆคือจะใช้ model : *intfloat/multilingual-e5-base* เป็น default

Link :

<https://github.com/mrpeerat/Thai-Sentence-Vector-Benchmark?tab=readme-ov-file#thai-retrieval-benchmark>

สำหรับ Link ด้านบน จะเป็น Benchmark ของ Model ที่จะบอกว่าตัวไหนเก่งไม่เก่ง

3.2) LLMs

ก็มีการเลือกมา 3 ด้วยเช่นกัน แต่ด้วยข้อจำกัดในด้าน resource จึงใช้ ChatGPT 3.5 Turbo เป็นหลัก

4. Application




Figure 1.7 Chatbot application

สำหรับหน้านี้คือหน้าตาของ application ก็จะมีลักษณะเป็นช่อง chat (Figure 1.7) และสามารถเลือก mode ตรงแถบด้านซ้ายได้ ก็จะมีอยู่ 3 mode ได้แก่ full option คือถามตอบเกี่ยวกับเอกสารที่เราได้ upload มี Mode ที่ใช้งานแค่ Embedding model อย่างเดียว ก็คือแค่จะค้นหาข้อความในเอกสารที่อาจเป็นคำตอบ และ Mode สุดท้ายคือ chat กับ LLMs เลยๆ ไม่มีการ upload เอกสาร

แล้วก็ในส่วนช่อง chat ก็จะมีการทดสอบ ถามคำถามใน mode full option ซึ่งถามเกี่ยวกับเอกสารที่ upload เกี่ยวกับ ดิจิทัลวอลเล็ต

ก็จะแบ่งส่วนที่เป็นคำตอบของ LLMs

ส่วนที่เป็น reference text ที่ได้มาจาก Embedding model

แล้วก็เวลาที่ใช้ในการ search เอกสารรวมถึงเวลาที่ใช้ในการ gen คำตอบ

5. Evaluation

ที่นี้ก็มาถึงส่วน Evaluation หรือการวัดผล

วิธีการวัดผลจะค่อนข้างวัดได้ยากเพราะมี Algorithm 2 ตัว และเป็นการวัดผลจาก text

ใน project นี้จะใช้วิธี Check จากตัว Embedding model อย่างเดียว และเราก็จะใช้ LLMs ตัวเดียวกันทั้งหมดในการวัดผล ก็คือจะดูว่า มีการ Search เอกสารตรงตามที่คิดไว้ไหม ถ้าตรงก็ให้คะแนนเป็น 1 ไม่ตรงก็ให้เป็น 0




Figure 1.8 Evaluation Method

หลักการคือ

จะมีการเอา text ส่งให้กับ LLMs แล้วให้ตัว LLMs ทำการ gen คำถามเกี่ยวกับ text นั้นออกมา

จากนั้นก็เอาคำถามที่ได้ ไป search ไม่ว่าจะด้วยวิธี semantic หรือ hybrid ก็ตาม

เราจะดูว่า text ที่ search ออกมา ตรงกับ text ที่ใช้ gen คำถามหรือไม่ (Figure 1.8)

สำหรับวิธีการสั่งให้ LLMs ทำการ gen คำถามออกมา

จะใช้วิธีการที่เรียกว่า few-shot learning prompt

และเอกสารที่นำมาใช้ในการวัดผล

ก็จะแบ่งเป็น 2 ส่วนใหญ่ๆ คือส่วนที่เป็นข้อความทั่วไป เช่น ข่าว เป็นต้น

อีกส่วนคือเอกสารที่เฉพาะเจาะจง ในที่นี้ก็คือ เอกสารเกี่ยวกับกฎหมาย PDPA

5.1) Results

intfloat/multilingual-e5-base (Default) : semantic search		
Overall	On Law document	On News
accuracy :	law-accuracy :	News-accuracy :
0.4241	0.3158	0.5434
intfloat/multilingual-e5-base (Default) : hybrid search		
accuracy :	law-accuracy :	News-accuracy :
0.3724	0.2631	0.4927
from 290 parts of document	from 152 parts of document	from 138 parts of document

Figure 1.9 Evaluation results

สำหรับหน้านี้คือ ผลลัพธ์

โดยจะมีการทดสอบ 2 วิธีคือ

5.1.1) ใช้ Semantic search

5.1.2) ใช้วิธีการ Hybrid search

ผลปรากฏว่าในภาพรวม Semantic search สามารถดึงเอกสารได้ตรงกว่า

และในส่วนของการแยกหมวดเอกสารทั่วไป กับเอกสารเฉพาะทาง ก็ปรากฏว่า Semantic search ทำได้ดีกว่า (Figure 1.9)

News

Q : วันวสันตวิษุวัตเกิดขึ้นกี่ครั้งต่อปี?

TRUE REFERENCE : แล้วขุสองแขนขึ้นฟ้า โดยผู้แสวงบุญเชื่อว่าสถานที่แห่งนี้มีพลังพิเศษโดยเฉพาะในวันวสันตวิษุวัต ซึ่งสามารถถ่ายทอดพลังสู่ผู้คนได้ โดยเฉพาะผู้ที่สวมชุดสีขาวสำหรับวัน “วสันตวิษุวัต” หรือกลางวันและกลางคืนยาวเท่ากันนั้น ถือเป็นวันเปลี่ยนฤดูกาลเข้าสู่ฤดูใบไม้ผลิของประเทศทางซีกโลกเหนือ และเปลี่ยนสู่ฤดูใบไม้ร่วงของประเทศในซีกโลกใต้จะเกิดขึ้นเพียง 2 ครั้งต่อปี ได้แก่ในช่วงเริ่มต้นของฤดูใบไม้ผลิ เรียกว่า วันวสันตวิษุวัต และในช่วงเริ่มต้นฤดูใบไม้ร่วง เรียกว่า วันศารทวิษุวัต (Autumnal Equinox)ทั้งนี้พระมิดสุรียันตั้งอยู่ในเมืองเดโอติฮัวคัน ห่างจากกรุงเม็กซิโก ซิตี้ ไปทางเหนือประมาณ 50 กิโลเมตร โดยเป็นเมืองโบราณก่อนยุคฮิสแปนิก ก่อตั้งขึ้นในช่วงสมัย 2 ศตวรรษก่อนการประสูติของพระคริสต์ และในช่วงรุ่งเรืองมีผู้นับอยู่อาศัยมากถึง 200,000 คน ก่อนที่เมืองจะถูกทิ้งร้างเกือบทั้งหมดในปีค.ศ. 750

RETRIEVE : 22 มี.ค. 2567 09:40 น.ข่าวต่างประเทศไทยรัฐออนไลน์ชาวเม็กซิโกร่วมฉลองวัน “วสันตวิษุวัต” กลางวันยาวเท่ากลางคืน-กกก+LightDarkฟังข่าวแชร์ข่าวชาวเม็กซิโกร่วมพิธีเฉลิมฉลองและรับพลังพิเศษ ในวัน “วสันตวิษุวัต” ซึ่งเป็นวันแรกของฤดูใบไม้ผลิ และกลางวันยาวเท่ากลางคืนสำนักข่าวเอพีรายงานว่า เมื่อวันที่ 21 มี.ค. 2567 ชาว

เม็กซิกันหลายสิบคน สวมชุดสีขาว ปีนขึ้นไปบน “พีระมิดสุรียัน” ที่สูงตระหง่านในเมืองเก่า เดโอติฮัวคัน เพื่อร่วมแสงบุญและเฉลิมฉลองวัน “วสันตวิษุวัต” (Spring Equinox) วันแรกของฤดูใบไม้ผลิ และกลางวันยาวเท่ากลางคืน เมื่อดวงอาทิตย์อยู่ในตำแหน่งตั้งฉากกับเส้นศูนย์สูตรของโลกพอดีผู้แสวงบุญจะหันหน้าไปยังทิศทางที่ดวงอาทิตย์โผล่ขึ้นเหนือขอบฟ้า แล้วขุสองแขนขึ้นฟ้า โดยผู้แสวงบุญเชื่อว่า สถานที่แห่งนี้มีพลังพิเศษโดยเฉพาะในวันวสันตวิษุวัต ซึ่งสามารถถ่ายทอดพลังสู่ผู้คนได้

Text 1.1

ส่วนนี้ (Text 1.1) คือตัวอย่างของ case ที่รับเอกสารมาไม่ตรง ของวิธีการ semantic search ส่วนที่เป็น true reference คือ text ที่นำมา gen คำถาม ส่วน retrieve คือ text ที่ embedding model search ได้ออกมา

News

Q : คำว่า e-Refund ความหมายคืออะไรและโครงการนี้มีผลกระทบต่อภาษีอย่างไรบ้าง?

TRUE REFERENCE : [โครงการ e-Refund ลดหย่อนภาษี ไม่เกิน 50,000 บาท สำหรับผู้ที่ได้สิทธิ์ ‘ดิจิทัลวอลเล็ต’] พร้อมกันนั้น เราจะใช้เงินในการเพิ่มขีดความสามารถ ภายใต้บง 1 แสนล้านบาท และส่งเสริมการลงทุนในเทคโนโลยีใหม่ๆ เช่น เทคโนโลยียานยนต์สมัยใหม่ อุตสาหกรรมดิจิทัล เกษตรและเทคโนโลยีชีวภาพ การพัฒนาบุคลากรทางการศึกษา เป็นต้น ซึ่งกองทุนนี้จะใช้ในการดึงดูดผู้มีความสามารถให้เข้ามามีส่วนร่วมในการสร้างการเจริญเติบโตทางเศรษฐกิจให้ต่อเนื่องต่อไป

RETRIEVE : นายเศรษฐา กล่าวยืนยันความตั้งใจที่จะให้คนไทยทุกคนมีส่วนร่วมในการกระตุ้นเศรษฐกิจนี้ เพราะฉะนั้นรัฐบาลจะออกโครงการ e-Refund ให้คนไทยสามารถ ลดหย่อนภาษีเงินได้บุคคลจากการซื้อสินค้าและบริการมูลค่าไม่เกิน 50,000 บาท โดยให้นำใบกำกับภาษีมาประกอบการยื่นภาษีบุคคล และรัฐจะคืนเงินภาษีให้ เพราะฉะนั้นคนที่ไม่ได้รับสิทธิ์ดิจิทัลวอลเล็ต ก็สามารถเข้าร่วมเป็นส่วนหนึ่งของการกระตุ้นเศรษฐกิจผ่านโครงการนี้ได้ และจะทำให้ร้านค้าในระบบภาษีดิจิทัลมากขึ้นด้วย นายกรัฐมนตรีกล่าวต่อว่า สรุปนโยบายทั้งหมดนี้จะส่งผลดีต่อประเทศใน 2 ด้าน

- 1. กระตุ้นเศรษฐกิจของประเทศในระยะสั้นโดยมีประชาชนทุกภาคส่วนเป็นกลไกที่สำคัญผ่านการบริโภคและการลงทุน
- 2. วางโครงสร้างพื้นฐานเพื่อนำไปสู่เศรษฐกิจดิจิทัลและ E-Government ซึ่งเป็นการวางและแก้ไขปัญหาละเอียดเชิงโครงสร้างของประเทศในระยะยาว

Text 1.2

ส่วนตรงนี้ (Text 1.2) คือ case ที่ search เอกสารออกมาได้ไม่ตรงกับเอกสารเริ่มต้น แต่ยังสามารถใช้ในการตอบคำถาม user ได้ ก็คือเอกสารไม่ตรงก็จริง แต่มีส่วนที่เป็นคำตอบ

6. Summary

- 6.1) Hybrid search อาจส่งผลให้ได้ผลลัพธ์ที่แย่กว่า Semantic search
- 6.2) วิธีการ Evaluate ที่ใช้กับ Project นี้ไม่สามารถตอบโจทย์กรณีที่ model รับเอกสารมาผิด แต่กลับตอบคำถามได้ดีกว่า

7. Future improvement

- 7.1) เพื่อการทดลองพัฒนาประสิทธิภาพในการ Search document อาจลองพิจารณาใช้ Graph Database
- 7.2) วิธีการ Evaluate อาจใช้ LLM ในการเทียบ Similarity ของ Documents เพื่อป้องกัน case fail แต่ยังคงตอบคำถามของ user ได้
- 7.3) สำหรับการตอบเอกสารที่เป็นข้อมูลขององค์กร หรือเอกสารเฉพาะทาง อาจจะต้องทำการ Train Embedding model เกี่ยวกับเรื่องนั้นๆขึ้นมาโดยเฉพาะ ในกรณีที่คาดหวังผลลัพธ์ที่ดีและแม่นยำมากขึ้น

REFERENCES

- 1.Topic : RAG-A survey, Link : <https://arxiv.org/abs/2312.10997> , Date : 18 Dec 2023
- 2.Topic : The Intersection of Artificial Intelligence and Law, Link : https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4632440 , Date : 22 Apr 2023
- 3.Topic : Chatbot application prototype, Link : <https://github.com/zylon-ai/private-gpt> , Date : 12 Aug 2024
- 4.Topic : N-Gram, Link : <https://web.stanford.edu/~jura/sky/slp3/3.pdf> , Date : 3 Feb 2024
- 5.Topic : Skip-Gram, Link : <https://arxiv.org/pdf/1310.4546> , Date : 16 Oct 2013
- 6.Topic : BM25, Link : <https://adasci.org/understanding-okapi-bm25-a-guide-to-modern-information-retrieval/> , Date : 11 Jul 2024
- 7.Topic : Github of this project, Link : <https://github.com/HikariJadeEmpire/LawDocuments-Chatbot> , Date : 1 Jan 2024